

데이터 분석을 통한 인사이트 도출 및 사망률 예측

MIMIC-IV
데이터 분석


MIMIC-IV
데이터 분석

20516104 황경하
20516005 권용진
20516035 노성진
20516048 배규민
20516097 최건희


20516104 황경하
20516005 권용진
20516035 노성진
20516048 배규민
20516097 최건희



목차

- 01 일반 환자, 중환자 (인종, 나이) 통계치 (SQL & Python)
 - 02 장기적인 치료가 필요한 질병 (SQL)
 - 03 치사율이 높은 질병 찾기 (SQL)
 - 04 사망률 예측 (Python)
- 

Intro



- 데이터 분석의 목적은 인사이트 도출.
- 우리는 이 인사이트로 인공지능을 개발하여 문제점 개선이 목표.

주제 설명

 청년 의사
<http://www.docdocdoc.co.kr/news/articleView> 

"의료인력 부족이 환자 위험으로 이어져...인력 확충하라 ..."
2023. 7. 4. — 지역 대학병원에서 근무하는 B 간호사는 의료인력 부족으로 실제로 환자가 사망하거나 심각한 상황에 빠졌던 경험을 토로했다. B 간호사는 “화상전문병원 ...

 동아일보
<https://www.donga.com/news/Society/article/all> 

의사 총파업 예고 환자들 '분통'...“수술 밀리나” “이기주의”
2024. 2. 7. — 정부의 의과대학 정원 확대 추진에 대한 의사협회(의협)가 '총파업'을 시사하면서 환자와 가족들의 불안이 커지고 있다. 정부는 내년부터 의대 정원을 2000 ...



 메디팜스투데이
<https://www.pharmstoday.com/news/의료/병원> 

병원협회, 의사인력 수급 개선 6가지 방안 제시
2024. 1. 23. — 병원협회는 의사인력 부족과 수급 불균형 등으로 병원 운영에 어려움을 호소하는 회원병원을 위해 지난해 7월부터 '의료인력 수급 개선 TF'를 구성하여 ...

 Oracle
<https://www.oracle.com/healthcare-workforce-retention> 

보건의료 인력 유지율 개선을 위한 7가지 전략
2023. 3. 17. — 간호사, 의사 및 기타 의료 종사자의 높은 이직률의 근본적인 원인은 보건의료 분야 전반의 의료 인력 부족입니다. 의사, 간호사 및 기타 의료진의 부족 ...

- 병원의 인력 부족 → 제한된 자원 속 우선 순위 판단 기준 필요
- 당장의 개선책 부족



데이터 알아보기:

일반 환자, 중환자 (인종, 나이) 통계치




01

일반 환자, 중환자 (인종, 나이) 통계치


두 데이터 모두 WHITE의 비율이 가장 높음

인종	인종 별_환자수
WHITE	121364
BLACK	23409
UNKNOWN	10104
LATINO	9765
ASIAN	7522
OTHER	7475
AMERICAN	617
MULTIPLE RACE/ETHNICITY	264
NATIVE HAWAIIAN OR OTHER PACIFIC ISLANDER	213

중환자 인종	인종 별_환자수
WHITE	34172
UNKNOWN	6405
BLACK	4584
LATINO	1730
OTHER	1701
ASIAN	1489
AMERICAN	127
NATIVE HAWAIIAN OR OTHER PACIFIC ISLANDER	77
MULTIPLE RACE/ETHNICITY	47



일반 환자 인종별 통계치



중환자 인종별 통계치

01

일반 환자, 중환자 (인종, 나이) 통계치

age_group	개 수
11-20	19369
21-30	59815
31-40	37916
41-50	33566
51-60	35712
61-70	28296
71-80	18492
81-90	11542
90+	4672

일반환자 나이대별 환자수

일반 - 연령대 별로 다양
중환자 - 고령층 다수

age_group	개 수
11-20	474
21-30	2314
31-40	2744
41-50	4978
51-60	9197
61-70	11509
71-80	10197
81-90	6783
90+	2136

중환자 나이대별 환자수



데이터 분석하기: 장기적인 치료가 필요한 질병 분석



02

장기적인 치료가 필요한 질병

icd진단코드	환자수
Y92230	32
E8798	22
Z781	18
Y92239	15
E8497	13
Z87891	11
Y848	10
V5867	10
V1582	9
D649	9

10 rows in set (0.041 sec)

입원 기간은 길지만, 사망률은 낮은 케이스

ICD 진단 코드 별 병명

- Y92230 : 병원내사고
- E8798 : 합병증
- Z781 : 신체적 제약
- Y92239 : 구체적으로 명시되지 않은 상태
- E8497 : 주거 기관에서 발생한 사고
- Z87891 : 니코틴 의존성
- Y848 : 합병증
- V5867 : 인슐린 장기 사용
- V1582 : 개인 흡연 이력
- D649 : 빈혈



데이터 분석하기: 치사율이 높은 질병찾기



03

치사율이 높은 질병찾기

병의 평균 사망위험도가 3.5 이상이며 사망률이 20% 이상인 병들

icd진단코드	icd버전	avg_사망위험도	count	사망자수	생존자수	사망률
2512	9	3.8	10	3	7	0.3000
E1122	10	3.789473684210526	19	5	14	0.2632
Z8674	10	3.7777777777777777	27	6	21	0.2222
K7290	10	3.764705882352941	17	4	13	0.2353
I129	10	3.75	12	3	9	0.2500
V1253	9	3.7142857142857144	14	6	8	0.4286
5712	9	3.6923076923076925	13	4	9	0.3077
E162	10	3.6923076923076925	39	12	27	0.3077
78551	9	3.6666666666666665	18	10	8	0.5556
99592	9	3.6545454545454548	55	12	43	0.2182
Z515	10	3.6033519553072626	179	100	79	0.5587
V667	9	3.5938242280285038	421	223	198	0.5297
R040	10	3.5294117647058822	17	4	13	0.2353
E8351	10	3.5	24	5	19	0.2083
5728	9	3.5	20	6	14	0.3000

- 2512 : 저혈당
- E1122 : 당뇨병
- Z8674 : 심장마비
- K7290 : 간부전
- I129 : 고혈압성 만성 신장 질환자

- V1253 : 심장마비
- 5712 : 알코올성 간경변증
- E162 : 저혈당
- 78551 : 심인성 쇼크
- 99592 : 중증 패혈증

- Z515 : 말기 질환 or 만성 질환
- V667 : 말기 질환 or 만성 질환
- R040 : 비출혈
- E8351 : 저칼슘혈증
- 5728 : 간 질환 후유증



모델링: 사망률 예측



04 Description

Python에서 전처리 후 SQL로 Bulk 수행

- admissions 테이블 → 인종, 결혼 상태, 사망 여부 추출
- patients 테이블 → 성별, 나이 추출
- icustays → 총 입원 기간 추출
- procedureevents → 체중 추출
- drgcodes → 사망 위험도 추출
- diagnoses_icd → icd 진단 코드, 해당 진단 코드의 ICD 버전 추출

04 DataFrame

환자id	성별	나이	인종	결혼 상태	icd 진단 코드	해당 진단 코드의 ICD 버전	체중	총 입원 기간	사망 위험도	사망여부
10000032	F	52	WHITE	WIDOWED	5715	9	39.4	1	3.0	0
10000980	F	73	BLACK/AFRICAN AMERICAN	MARRIED	E8497	9	76.2	1	4.0	0
10001217	F	55	WHITE	MARRIED	V161	9	74.8	3	4.0	0
10001725	F	46	WHITE	MARRIED	78052	9	72.2	2	1.0	0
10001884	F	68	BLACK/AFRICAN AMERICAN	MARRIED	T45515A	10	65.0	10	3.0	0
...	...	...	...	...	...	...	...	...	...	...
19999442	M	41	WHITE	SINGLE	311	9	107.5	7	4.0	0
19999625	M	81	WHITE	MARRIED	V4589	9	50.5	1	4.0	0
19999828	F	46	WHITE	SINGLE	I9581	10	67.9	2	2.0	0
19999840	M	58	WHITE	WIDOWED	E912	9	77.5	6	4.0	1
19999987	F	57	UNKNOWN	UNKNOWN	7810	9	94.0	2	4.0	0

50332 rows × 10 columns

04 Preprocessing

	gender	age	weight	stay	morality	die_flag	race_ASIAN	race_BLACK	race_LATINO	race_MULTIPLE RACE/ETHNICITY	HAWAIIAN OR OTHER PACIFIC ISLANDER	race_OTHER	race_UNKNOWN	race_WHITE	icd_code_encoded	marital_MARRIED
환자id																
10000032	0	52	39.4	1	3.0	0	0	0	0	0	0	0	0	1	28195	0
10000980	0	73	76.2	1	4.0	0	0	1	0	0	0	0	0	0	28195	1
10001217	0	55	74.8	3	4.0	0	0	0	0	0	0	0	0	1	28195	1
10001725	0	46	72.2	2	1.0	0	0	0	0	0	0	0	0	1	28195	1
10001884	0	68	65.0	10	3.0	0	0	1	0	0	0	0	0	0	22137	1
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
19999442	1	41	107.5	7	4.0	0	0	0	0	0	0	0	0	1	28195	0
19999625	1	81	50.5	1	4.0	0	0	0	0	0	0	0	0	1	28195	1
19999828	0	46	67.9	2	2.0	0	0	0	0	0	0	0	0	1	22137	0
19999840	1	58	77.5	6	4.0	1	0	0	0	0	0	0	0	1	28195	0
19999987	0	57	94.0	2	4.0	0	0	0	0	0	0	0	1	0	28195	0

50332 rows x 19 columns

1. 성별 인코딩 → M: 1, F: 0
2. 인종 더미 variable 생성 → 9개의 column 추가 생성.
3. icd 진단 코드 빈도 인코딩 → 범주가 너무 많아 빈도수로 인코딩

04 Model Comparison

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC	TT (Sec)
gbc	Gradient Boosting Classifier	0.9130	0.8213	0.0652	0.5333	0.1156	0.0984	0.1629	
lightgbm	Light Gradient Boosting Machine	0.9128	0.8189	0.0603	0.5201	0.1077	0.0912	0.1542	
ada	Ada Boost Classifier	0.9124	0.8146	0.0449	0.5155	0.0820	0.0687	0.1302	
ridge	Ridge Classifier	0.9124	0.7862	0.0000	0.0000	0.0000	0.0000	0.0000	
dummy	Dummy Classifier	0.9124	0.5000	0.0000	0.0000	0.0000	0.0000	0.0000	
lr	Logistic Regression	0.9120	0.7823	0.0057	0.2850	0.0110	0.0084	0.0302	
lda	Linear Discriminant Analysis	0.9110	0.7861	0.0636	0.4476	0.1108	0.0911	0.1420	
xgboost	Extreme Gradient Boosting	0.9091	0.8005	0.0919	0.4170	0.1503	0.1226	0.1632	
knn	K Neighbors Classifier	0.9074	0.6206	0.0223	0.2228	0.0404	0.0247	0.0446	
rf	Random Forest Classifier	0.9065	0.7791	0.0996	0.3733	0.1569	0.1248	0.1562	
et	Extra Trees Classifier	0.8993	0.7551	0.1101	0.2969	0.1604	0.1188	0.1356	
nb	Naive Bayes	0.8581	0.7424	0.2972	0.2464	0.2692	0.1915	0.1926	
dt	Decision Tree Classifier	0.8551	0.5772	0.2397	0.2114	0.2245	0.1450	0.1454	
qda	Quadratic Discriminant Analysis	0.8551	0.7427	0.3190	0.2475	0.2786	0.1986	0.2016	
svm	SVM - Linear Kernel	0.8299	0.5613	0.1000	0.0088	0.0161	0.0000	0.0000	

Accuracy Top 3:

- 1) gbc → 정확도 91.3%
- 2) lgbm → 정확도 91.28%
- 3) ada boost → 정확도 91.24%

04 Tunned GBC model

	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
Fold							
0	0.9142	0.7983	0.0445	0.6471	0.0833	0.0729	0.1541
1	0.9142	0.8349	0.0607	0.6000	0.1103	0.0957	0.1714
2	0.9152	0.8179	0.0567	0.7000	0.1049	0.0930	0.1831
3	0.9142	0.8364	0.0567	0.6087	0.1037	0.0901	0.1672
4	0.9131	0.8190	0.0688	0.5312	0.1219	0.1039	0.1681
5	0.9145	0.8262	0.0769	0.5938	0.1362	0.1185	0.1918
6	0.9116	0.8079	0.0567	0.4667	0.1011	0.0837	0.1390
7	0.9113	0.8145	0.0486	0.4444	0.0876	0.0716	0.1241
8	0.9145	0.8314	0.0607	0.6250	0.1107	0.0967	0.1761
9	0.9127	0.8384	0.0405	0.5263	0.0752	0.0635	0.1278
Mean	0.9135	0.8225	0.0571	0.5743	0.1035	0.0889	0.1603
Std	0.0012	0.0126	0.0103	0.0765	0.0172	0.0157	0.0220

Fitting 10 folds for each of 10 candidates, totalling 100 fits

정확도 약 0.5% 증가

04 Tunned LGBM model

	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
Fold							
0	0.9138	0.8004	0.0405	0.6250	0.0760	0.0661	0.1436
1	0.9156	0.8336	0.0769	0.6552	0.1377	0.1215	0.2047
2	0.9156	0.8131	0.0688	0.6800	0.1250	0.1107	0.1982
3	0.9149	0.8330	0.0526	0.6842	0.0977	0.0863	0.1738
4	0.9120	0.8211	0.0567	0.4828	0.1014	0.0846	0.1425
5	0.9123	0.8234	0.0405	0.5000	0.0749	0.0626	0.1233
6	0.9131	0.8078	0.0567	0.5385	0.1026	0.0873	0.1538
7	0.9138	0.8186	0.0607	0.5769	0.1099	0.0948	0.1670
8	0.9123	0.8328	0.0567	0.5000	0.1018	0.0855	0.1461
9	0.9134	0.8337	0.0445	0.5789	0.0827	0.0711	0.1431
Mean	0.9137	0.8218	0.0555	0.5821	0.1010	0.0870	0.1596
Std	0.0012	0.0113	0.0112	0.0724	0.0191	0.0176	0.0248

Fitting 10 folds for each of 10 candidates, totalling 100 fits

정확도 약 0.9% 증가 &
GBC 모델 능가

04 Blending Model

	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
Fold							
0	0.9138	0.8006	0.0405	0.6250	0.0760	0.0661	0.1436
1	0.9149	0.8352	0.0648	0.6400	0.1176	0.1032	0.1848
2	0.9149	0.8169	0.0526	0.6842	0.0977	0.0863	0.1738
3	0.9159	0.8357	0.0648	0.7273	0.1190	0.1061	0.2006
4	0.9117	0.8213	0.0526	0.4643	0.0945	0.0781	0.1334
5	0.9152	0.8267	0.0688	0.6538	0.1245	0.1097	0.1932
6	0.9116	0.8093	0.0526	0.4643	0.0945	0.0781	0.1334
7	0.9131	0.8182	0.0526	0.5417	0.0959	0.0817	0.1488
8	0.9138	0.8334	0.0567	0.5833	0.1033	0.0892	0.1625
9	0.9131	0.8375	0.0405	0.5556	0.0755	0.0643	0.1327
Mean	0.9138	0.8235	0.0547	0.5939	0.0999	0.0863	0.1607
Std	0.0014	0.0118	0.0091	0.0840	0.0159	0.0151	0.0247

정확도 약 0.1% 증가



04 Evaluate


	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	Voting Classifier	0.9158	0.8279	0.0614	0.7013	0.1130	0.1003	0.1909

```
[LightGBM] [Warning] feature_fraction is set=0.8, colsample_bytree=1.0 will be ignored. Current value: feature_fraction=0.8
[LightGBM] [Warning] bagging_freq is set=5, subsample_freq=0 will be ignored. Current value: bagging_freq=5
[LightGBM] [Warning] bagging_fraction is set=0.6, subsample=1.0 will be ignored. Current value: bagging_fraction=0.6
[LightGBM] [Warning] feature_fraction is set=0.8, colsample_bytree=1.0 will be ignored. Current value: feature_fraction=0.8
[LightGBM] [Warning] bagging_freq is set=5, subsample_freq=0 will be ignored. Current value: bagging_freq=5
[LightGBM] [Warning] bagging_fraction is set=0.6, subsample=1.0 will be ignored. Current value: bagging_fraction=0.6
```

Test data에 대하여 약 91.58%의 정확도를 기록

04

ROC CURVE



1에 가까운 결과를 보여줌.

04 Result

중환자를 대상으로 한 데이터이다 보니
사망위험도가 높은 사람들이 다수.
따라서, 모델도 사망 위험도가 매우 높다고 예측함.

환자 id	die_flag	prediction_label	morality	prediction_morality	prediction_score
13336130	0	0	4.0	4	0.8777
10240784	0	0	4.0	4	0.9082
19587449	0	0	4.0	4	0.8121
12759587	0	0	4.0	4	0.8162
16615729	0	0	3.0	4	0.9736
...	...	...	...	...	...
16626888	0	0	4.0	4	0.8669
14032639	0	0	3.0	4	0.9818
19005999	0	0	4.0	4	0.9348
16433543	0	0	4.0	4	0.7931
12601251	0	0	4.0	4	0.8629

10067 rows × 5 columns

04 Conclusion

1. 의료 자원이 부족한 상황에서 우선 순위 판단 기준은 필요하며,
그 기준으로 사망 위험도는 매우 합리적인 방안이다.
2. 사망률을 완벽히 예측하기에 환자의 정보가 부족하다.
→ 환자에 대한 디테일 한 정보가 있다면 신뢰성 있는 예측이 가능할 수 있다.
3. 원본 데이터에 사망 위험도를 계산하는 매커니즘과 비교하여
그 방법이 더 합리적이라면, 우리의 결과를 개선 시킬 수 있다.

감사합니다

